
Diagnostic du jeu de données

Pourquoi les modèles ne séparent pas correctement les classes *High* et *Low*

Objectif de la note : montrer, à partir de plusieurs angles d'analyse complémentaires, que les performances limitées observées ne proviennent pas d'un choix de modèle inadapté, mais d'un manque de signal statistique dans le jeu de données pour séparer les patients *High* et *Low*.

Données analysées : 174 982 observations
Variable cible : niveau de risque (*High* / *Low*)

Table des matières

1	Contexte et objectif	2
2	Description du jeu de données	2
3	Les modèles convergent tous vers le hasard	3
3.1	Synthèse des indicateurs	3
3.2	L'accuracy masque l'absence de séparation réelle	4
4	Les variables explicatives portent très peu de signal	4
4.1	Pouvoir discriminant univarié	5
4.2	Des écarts de moyenne quasiment nuls entre les classes	6
4.3	Un chevauchement quasi total des distributions	6
4.4	Les variables catégorielles n'apportent pas plus de séparation	6
5	Synthèse générale	8
6	Recommandations	9

1. Contexte et objectif

Plusieurs familles de modèles de classification (régression logistique, arbres de décision, Random Forest, XGBoost, MLP) ont été entraînées pour prédire si un patient appartient à la classe *High* ou *Low*. Quel que soit le modèle utilisé, les performances obtenues restent décevantes sur les métriques qui comptent réellement pour un problème déséquilibré (AUC, F1 macro, recall de la classe minoritaire).

Cette note a pour but de déterminer l'origine de cette limite : vient-elle d'un mauvais choix d'algorithme, ou le jeu de données lui-même contient-il trop peu de signal pour séparer les deux classes ? Pour répondre à cette question, nous combinons trois angles d'analyse :

1. la comparaison des performances entre familles de modèles très différentes (section 3) ;
2. le pouvoir discriminant de chaque variable, prise isolément (section 4) ;
3. le chevauchement direct des distributions *High* / *Low* (section 4.3).

2. Description du jeu de données

Le jeu de données contient **174 982 lignes**, réparties en **125 781 observations *High*** et **49 201 observations *Low***. La classe *High* représente donc **71,9 %** des données : il s'agit d'un problème de classification déséquilibré, avec un ratio proche de 2,5 pour 1 en faveur de la classe majoritaire.




Figure 1: Répartition de la variable cible entre les classes *High* et *Low*.

Lecture du graphique

La classe *High* domine largement le jeu de données. Un modèle qui prédirait systématiquement *High* obtiendrait déjà une accuracy proche de 72 %, sans avoir rien appris sur la distinction entre les deux classes. C'est ce biais qu'il faut garder en tête pour interpréter correctement les résultats des sections suivantes.

3. Les modèles convergent tous vers le hasard

Si la faiblesse des résultats venait d'un choix de modèle inadapté, on s'attendrait à voir au moins une famille se détacher nettement des autres. Ce n'est pas le cas : régression logistique, arbres, Random Forest, XGBoost et MLP obtiennent des scores très proches les uns des autres sur les métriques clés.

3.1. Synthèse des indicateurs

Indicateur	Meilleure valeur	Interprétation
Accuracy	71,89 %	trompeuse : elle profite surtout de la sur-représentation de <i>High</i>
AUC	0,5046	très proche de 0,50 : séparation quasi nulle entre <i>High</i> et <i>Low</i>
F1 macro	0,4988	équilibre faible entre les deux classes

Table 1: Meilleures valeurs observées, toutes familles de modèles confondues.




Figure 2: AUC obtenue par chaque modèle. La ligne rouge marque le niveau du hasard (0,50).

Lecture du graphique

Tous les modèles se regroupent dans une bande très étroite autour de $AUC = 0,50$. Le meilleur score (MLP, 0,5046) n'est que marginalement supérieur au hasard, et certains modèles (Random Forest, régression logistique) se retrouvent même légèrement en dessous. Aucune famille de modèle ne se distingue : le problème n'est donc pas algorithmique.




Figure 3: Accuracy et AUC pour chaque modèle. Les deux métriques ne racontent pas la même histoire.

3.2. L'accuracy masque l'absence de séparation réelle

Lecture du graphique

Les modèles les plus performants en accuracy (XGBoost, MLP, autour de 72 %) ne sont pas ceux qui séparent le mieux les classes : leur AUC reste proche de 0,50. À l'inverse, le modèle avec la plus faible accuracy (MLP avec pondération des classes minoritaires, `pos_weight`) est aussi celui qui s'écarte le plus du hasard sur l'AUC. Cela confirme qu'une bonne accuracy peut être obtenue *en exploitant le déséquilibre des classes*, sans que le modèle apprenne une vraie frontière de décision.

À retenir

Pour ce type de problème déséquilibré, l'accuracy seule ne suffit pas à juger un modèle. Il faut systématiquement regarder le **recall de la classe minoritaire (*Low*)**, le **F1 macro** et l'**AUC**. Sur ces trois indicateurs, les meilleurs scores restent faibles, quel que soit le modèle testé.

4. Les variables explicatives portent très peu de signal

Pour vérifier si le problème vient du dataset plutôt que des modèles, chaque variable a été testée **isolément**, indépendamment de tout algorithme complexe.




Figure 4: Recall obtenu séparément sur la classe *Low* et sur la classe *High*.




Figure 5: F1 macro par modèle. La ligne rouge indique une référence faible (0,50).

4.1. Pouvoir discriminant univarié

Chaque variable numérique a été évaluée seule via une AUC univariée (variable contre cible, sans aucun autre prédicteur). Le meilleur résultat reste très faible : **0,5026** pour le cholestérol, soit à peine au-dessus du hasard.

Lecture du graphique

Si une variable séparait clairement *High* et *Low*, son AUC univariée serait nettement su-




Figure 6: AUC obtenue par chaque variable numérique prise isolément.

périeure à 0,50 (par exemple au-dessus de 0,65–0,70 pour une variable réellement utile en pratique clinique). Ici, toutes les variables restent collées à la ligne du hasard, cholestérol compris.

4.2. Des écarts de moyenne quasiment nuls entre les classes

La plus grande différence standardisée observée entre les deux classes vaut seulement **0,0090** (cholestérol). À titre de comparaison, un effet est généralement considéré comme faible à partir de 0,10 et comme notable à partir de 0,20 (lignes de référence orange et rouge sur le graphique). On en est ici très loin : les moyennes des deux classes sont quasiment identiques sur l'ensemble des variables numériques.

4.3. Un chevauchement quasi total des distributions

Lecture du graphique

Les histogrammes superposés des deux classes se recouvrent presque parfaitement pour l'âge, l'IMC, le cholestérol, les pressions systolique et diastolique, ainsi que le glucose. Aucune de ces variables ne présente de zone de valeurs typique d'une seule des deux classes.

4.4. Les variables catégorielles n'apportent pas plus de séparation

La variable catégorielle la plus discriminante reste **country**, avec un écart maximal de seulement **1,47 point de pourcentage** du taux de *High* entre ses modalités — bien en dessous




Figure 7: Différence standardisée (effect size) entre *High* et *Low* pour chaque variable numérique.




Figure 8: Distributions de l'âge, l'IMC, le cholestérol, la pression artérielle et le glucose pour les deux classes.

du seuil de 5 points qui marquerait une variable véritablement informative. Les autres variables (`physical_activity_level`, `employment_status`, `smoking_status`, `gender`, `education_level`, `diabetes`, `family_history`) présentent des écarts encore plus faibles.




Figure 9: Amplitude du taux de *High* selon les modalités de chaque variable catégorielle.

À retenir

Que l'on regarde les variables numériques (AUC univariée, écarts standardisés, chevauchement des distributions) ou les variables catégorielles (variation du taux de *High*), le constat est le même : **aucune variable du jeu de données ne porte un signal suffisant** pour séparer correctement *High* et *Low*.

5. Synthèse générale

Les trois angles d'analyse convergent vers la même conclusion :

- **Côté modèles** – régression logistique, arbres, Random Forest, XGBoost et MLP obtiennent des AUC toutes proches de 0,50 et des F1 macro inférieurs à 0,50. Aucune famille ne se détache.
- **Côté variables** – prises isolément, les variables numériques atteignent au mieux une AUC de 0,5026, avec des écarts standardisés inférieurs à 0,01 entre les deux classes.
- **Côté distributions** – les histogrammes de *High* et *Low* se superposent presque intégralement sur toutes les variables médicales étudiées, et les variables catégorielles ne font varier le taux de *High* que de 1 à 2 points au maximum.

À retenir

Les modèles testés ne sont pas en cause : le jeu de données actuel ne contient probablement **pas assez de signal** pour prédire de manière fiable l'appartenance à la classe *High* ou *Low*. Toute amélioration future doit donc porter en priorité sur les **données** plutôt que sur le **choix** ou le **réglage des modèles**.

6. Recommandations

Sur la base de ce diagnostic, trois pistes complémentaires sont proposées :

1. **Revoir la construction de la variable cible.** Vérifier la règle (seuils, formule, source) qui a permis de classer un patient en *High* ou *Low*. Si la cible est elle-même bruitée ou partiellement aléatoire, aucun modèle ne pourra la prédire de manière fiable, quel que soit le nombre de variables disponibles.
2. **Enrichir le jeu de données avec des variables plus informatives.** Les variables actuelles (données démographiques et biologiques de base) ne suffisent pas. Des variables cliniques complémentaires, des données longitudinales (évolution dans le temps) ou des informations issues d'examens plus spécifiques pourraient apporter un signal supplémentaire.
3. **Documenter et communiquer ce diagnostic avant toute nouvelle itération de modélisation.** Continuer à tester de nouveaux algorithmes ou à optimiser des hyperparamètres sur ce jeu de données, en l'état, a peu de chances d'améliorer significativement les résultats : l'effort doit se porter sur la donnée en amont.